Engenho de busca para smartphones

Equipe:

Carlos Henrique Caloete Pena (chcp) Matheus Branco de Siqueira (mbs8)

O domínio

- O domínio escolhido possui muitos sites pela a internet o que facilita encontrar resultados relevantes
- Milhares de modelos de smartphones
- Interesse em obter informações sobre smartphones

Sites escolhidos

- Amazon
- Avenida
- Cissa Magazine
- Colombo
- Havan
- iByte
- Kabum
- Magazine Luiza
- Ricardo Eletro
- Taqi

Crawler

Dificuldades

- Tempo de coleta
- Páginas não encontradas
- Instabilidade da conexão
- Permissão negada pelo robots
- Sites instáveis

404
Page not found





Bibliotecas utilizadas





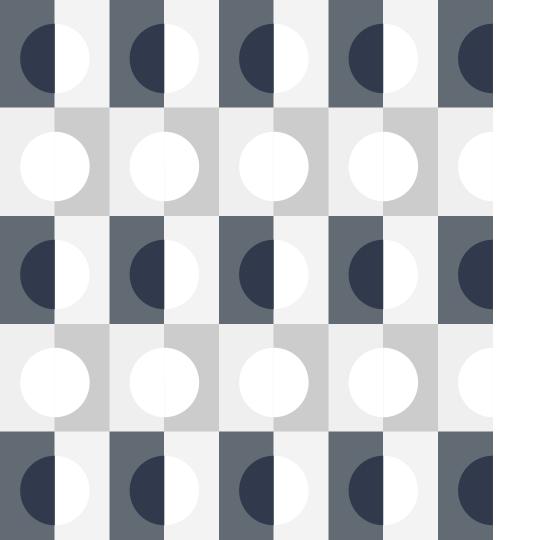




Beautifuloup

Urllib

Threading



Estratégias utilizadas

- 1. BFS
- 2. Palavras-chave nos links
- 3. Classificador de links

1. BFS

Prós

- Coleta "rápida"
- o Simplicidade de implementação

Contras

- Coleta muito superficial
- o Links que se afastam do domínio
- o Retorna menos links válidos

url	pages	total_links	loss
havan	966	1027	5,94%
promobit	1016	1017	0,10%
amazon	1019	1027	0,78%
ibyte	1001	1005	0,40%
avenida	1002	1007	0,50%
cissamagazine	1105	1109	0,36%
magazineluiza	999	1015	1,58%
taqi	1011	1014	0,30%
colombo	972	1034	6,00%
kabum	1033	1035	0,19%

Resultado do bfs_crawler (bfs_stats)

2. Heurística com palavras-chave

Prós

- Retorna mais links relevantes
- Menos links quebrados
- Coleta mais profunda

Contras

Coleta mais lenta

url	pages	total_links	loss	
colombo	878	1005	12,64%	
havan	1007	1007	0,00%	
amazon	1025	1025	0,00%	
cissamagazine	1034	1036	0,19%	
taqi	999	1001	0,20%	
ibyte	1001	1001	0,00%	
magazineluiza	995	1003	0,80%	
promobit	972	1004	3,19%	
avenida	1018	1018	0,00%	
kabum	1001	1002	0,10%	

Resultado do heuristic_crawler (heuristic_stats)

3. Classificador de links

Feature extractor utilizado: tf idf

```
text_clf = Pipeline([
    ('tfidf', CountVectorizer()),
    ('tranf', DenseTransformer()),
    ('clf', RandomForestClassifier(n_estimators=200, n_jobs=3)),
])
```

Prós

- Adaptação e aprendizagem
- Consegue generalizar mais facilmente

Contras

- Requer base de dados para treinar
- Maior custo em tempo

url	pages	total_links	loss
cissamagazine	936	1000	6,40%
avenida	1000	1000	0,00%
kabum	1000	1000	0,00%
amazon	982	1000	1,80%
ricardoeletro	772	1000	22,80%

Resultado do classifier_crawler (classifier_crawler)

Comparando Resultados

Estratégia	Páginas relevantes	Total de páginas	Harvest ratio	Ganho
BFS	685	10124	6,77%	-
Palavras-chave	2209	9930	22,25%	15,48%
Classificador de links	2302	4690	49,08%	26,83%

Classificador

Dificuldades

- Precisão das anotações
- Dados ruidosos
- Server Busy

store	link	text	label
magazinelu 🔻	$https://www.magazineluiza.com.br/celulares-e-telefon \ \overline{}$	Celular e Smartphone Magazii 🔻	0 =
amazon	http://www.amazon.com.br/Celular-Xiaomi-Redmi-Vers%C39	Celular Xiaomi Redmi Note GB F	1
amazon	http://www.amazon.com.br/Celular-Xiaomi-Redmi-Vers%C39	Celular Xiaomi Redmi Note GB F	1
amazon	http://www.amazon.com.br/Celular-Redmi-Note-128GB-Nept	Celular Redmi Note GB GB Nep	1
amazon	https://www.amazon.com.br/Celular-Redmi-Note-128GB-Nep	Celular Redmi Note GB GB Nep	1
amazon	https://www.amazon.com.br/Celular-Redmi-Note-128GB-Nep	Celular Redmi Note GB GB Nep	1
amazon	https://www.amazon.com.br/Celular-Redmi-Note-128GB-Nep	Celular Redmi Note GB GB Nep	1
amazon	https://www.amazon.com.br/Celular-Redmi-Note-128GB-Nep	Celular Redmi Note GB GB Nep	1
amazon	https://www.amazon.com.br/Celular-Redmi-Note-128GB-Nep	Celular Redmi Note GB GB Nep	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-Lite-Global-1280	Celular Xiaomi Mi Lite Global Dual	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-Lite-Global-1280	Celular Xiaomi Mi Lite Global Dual	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-Lite-Global-1280	Celular Xiaomi Mi Lite Global Dual	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-Lite-Global-1280	Celular Xiaomi Mi Lite Global Dual	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-Lite-Global-1280	Celular Xiaomi Mi Lite Global Dual	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-Lite-Global-1280	Celular Xiaomi Mi Lite Global Dual	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-Lite-Global-1280	Celular Xiaomi Mi Lite Global Dual	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-Lite-Global-1280	Celular Xiaomi Mi Lite Global Dual	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-MI-9T-Dual/dp/B	Celular Xiaomi MI T Dual GB Pre	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-MI-9T-Dual/dp/B	Celular Xiaomi MI T Dual GB Pre	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-Vers%C3%A3o-	Celular Xiaomi Mi Play GB GB RA	1
amazon	https://www.amazon.com.br/Celular-Xiaomi-Vers%C3%A3o-	Celular Xiaomi Mi Play GB GB RA	1
amazon	https://www.amazon.com.br/Smartphone-Motorola-Moto-XT1	Smartphone Motorola Moto G XT	1
amazon	https://www.amazon.com.br/Smartphone-Motorola-Moto-XT1	Smartphone Motorola Moto G Plus	1
amazon	https://www.amazon.com.br/Smartphone-Samsung-Galaxy-S	Smartphone Samsung Galaxy Note	1
amazon	https://www.amazon.com.br/Smartphone-Samsung-Galaxy-S	Smartphone Samsung Galaxy Note	1
amazon	https://www.amazon.com.br/Smartphone-Motorola-Action-XT	Smartphone Motorola One Action X1	1
amazon	https://www.amazon.com.br/Smartphone-Motorola-Action-XT	Smartphone Motorola One Action XT	1
amazon	https://www.amazon.com.br/Smartphone-Motorola-Action-XT	Smartphone Motorola One Action X1	1
amazon	https://www.amazon.com.br/Smartphone-Motorola-Action-XT	Smartphone Motorola One Action X1	1
amazon	https://www.amazon.com.br/Smartphone-Motorola-Action-XT	Smartphone Motorola One Action XT	1
	handless and half-real-based former former	Constitution Commission Colonia Con-	

Estratégias utilizadas

Celular, Xiaomi, Redmi Note 7, 4GB RAM, 64GB, Versão Global, 6.3", Azul: Amazon.com.br: Celulares e Telefonia - Google Chrome

Dado uma página fazer a coleta de texto

- Link
- Cabeçalho
- Dados dentro de tabelas

android
1 Polímero de lítio baterias ou pilhas necessárias (inclusas)
REDMI-NT7-128-BLU
HSDPA, 4G, 3G, GSM, Wifi, 2G
4G, 3G, Wifi, Bluetooth Wireless, 2G
Neptune Blue
4000 milliampere_hour
23 horas
6.3 polegadas
4 GB

Metodologia de Testes

- Foram anotados manualmente mais de 2600 páginas de 10 sites diferentes
- Foi utilizado a divisão Leave One Group Out, para obter as métricas
 - Onde o grupo da página seria o domínio
- Foram testadas seis máquinas de aprendizagem
 - o GaussianNb, DecisionTree, SVC, MLP, LogisticRegression, RandomForest
- Com três variações no pré processamento dos dados
 - Usar apenas palavras em caixa baixa
 - Eliminar Stop words
 - Utilizar TF IDF

				GaussianNb			
Lower	Stop Words	TF IDF		Acuracy	Precision	Recall	Train Time
			Mean	0.8336	0.8097	0.7549	0.1257
0	0	0	Std	0.2000	0.2417	0.2345	0.0123
			Mean	0.7658	0.7442	0.7225	0.1384
0	0	1	Std	0.2383	0.2106	0.2403	0.0307
			Mean	0.8714	0.8284	0.7881	0.1372
0	1	0	Std	0.1735	0.2432	0.2364	0.0129
			Mean	0.8286	0.7883	0.7729	0.0841
0	1	1	Std	0.1950	0.1990	0.2377	0.0193
			Mean	0.7616	0.7903	0.7347	0.0721
1	0	0	Std	0.2448	0.2013	0.2069	0.0096
			Mean	0.7470	0.7249	0.7285	0.3708
1	0	1	Std	0.2211	0.1920	0.2182	0.0326
			Mean	0.7748	0.7870	0.7325	0.0819
1	1	0	Std	0.2155	0.1966	0.2026	0.0113
			Mean	0.7642	0.7160	0.7335	0.0771
1	1	1	Std	0.2094	0.2115	0.2329	0.0103

					Decision	Tree	
	Stop Words	TF IDF		Acuracy	Precision	Recall	Train Time
			Mean	0.8670	0.8103	0.7993	0.3496
0	0	0	Std	0.1585	0.2178	0.2165	0.1135
			Mean	0.8215	0.8219	0.7822	0.3721
0	0	1	Std	0.2045	0.1782	0.1897	0.0936
			Mean	0.8653	0.8183	0.7992	0.2882
0	1	0	Std	0.1580	0.2231	0.2157	0.0857
			Mean	0.8230	0.8163	0.7981	0.2500
0	1	1	Std	0.2100	0.1933	0.1983	0.0697
			Mean	0.8581	0.8133	0.7883	0.1856
1	0	0	Std	0.1546	0.2206	0.2067	0.0582
			Mean	0.7985	0.7954	0.7635	1.0199
1	0	1	Std	0.2015	0.1632	0.1779	0.2964
			Mean	0.8589	0.8140	0.7923	0.2269
1	1	0	Std	0.1558	0.2213	0.2107	0.0758
			Mean	0.8243	0.8158	0.8093	0.2224
1	1 1	1	Std	0.2144	0.1725	0.1961	0.0654

					SVC		
Lower	Stop Words	TF IDF		Acuracy	Precision	Recall	Train Time
			Mean	0.8270	0.7813	0.6634	2.7348
0	0	0	Std	0.1354	0.2239	0.1811	0.6833
			Mean	0.7501	0.3750	0.5000	4.0000
0	0	1	Std	0.1490	0.0745	0.0000	0.0000
			Mean	0.8181	0.7027	0.6350	3.0566
0	1	0	Std	0.1307	0.2382	0.1837	0.6328
			Mean	0.7501	0.3750	0.5000	3.0000
0	1	1	Std	0.1490	0.0745	0.0000	0.0000
			Mean	0.8046	0.7873	0.6648	6.1887
1	0	0	Std	0.1740	0.2376	0.2148	4.1193
			Mean	0.7501	0.3750	0.5000	14.0000
1	0	1	Std	0.1490	0.0745	0.0000	2.0000
			Mean	0.8057	0.7380	0.6426	1.9738
1	1	0	Std	0.1531	0.2505	0.2055	0.4315
			Mean	0.7501	0.3750	0.5000	2.0000
1	1	1	Std	0.1490	0.0745	0.0000	0.0000

					MLP		
Lower	Stop Words	TF IDF		Acuracy	Precision	Recall	Train Time
			Mean	0.8903	0.8665	0.8474	11.6260
0	0	0	Std	0.1536	0.1699	0.1606	3.0704
	100000000000000000000000000000000000000		Mean	0.8696	0.8304	0.8087	9.8523
0	0	1	Std	0.1760	0.1982	0.2362	1.6026
	1		Mean	0.8852	0.8599	0.8567	9.0294
0		1	0	Std	0.1575	0.1808	0.1676
	1		Mean	0.8762	0.8218	0.8638	5.0464
0		1	Std	0.1689	0.2038	0.1915	0.7650
			Mean	0.8879	0.8227	0.8338	24.8311
1	0	0	Std	0.1517	0.2118	0.1945	3.3435
********			Mean	0.8552	0.7737	0.8226	24.0375
1	0	1	Std	0.1487	0.2027	0.1892	7.1442
			Mean	0.9028	0.8746	0.8876	5.1970
1	1	0	Std	0.1513	0.1615	0.1569	0.8987
			Mean	0.8943	0.8434	0.8878	4.9544
1	1	1	Std	0.1525	0.1760	0.1634	0.8416

					LogisticRegr	ession	ion		
Lower	Stop Words	TF IDF		Acuracy	Precision	Recall	Train Time		
			Mean	0.8875	0.8882	0.8129	0.2511		
0	0	0	Std	0.1495	0.1546	0.1711	0.0691		
			Mean	0.8590	0.8390	0.7843	0.2204		
0	0	1	Std	0.1697	0.2013	0.2006	0.0241		
			Mean	0.8944	0.8955	0.8381	0.1706		
0	1	0	Std	0.1572	0.1590	0.1776	0.0448		
			Mean	0.8767	0.8534	0.8314	0.1513		
0	1	1	Std	0.1609	0.1873	0.1844	0.0168		
			Mean	0.8878	0.8802	0.8396	0.9416		
1	0	0	Std	0.1538	0.1519	0.1713	0.1204		
			Mean	0.8590	0.8464	0.7930	0.1818		
1	0	1	Std	0.1523	0.1809	0.1717	0.0286		
	1 0				Mean	0.8988	0.8949	0.8654	0.1373
1		0	Std	0.1564	0.1542	0.1719	0.0129		
			Mean	0.8728	0.8527	0.8307	0.1300		
1	1	1	Std	0.1562	0.1822	0.1753	0.0115		

					RandomF	orest	
Lower	Stop Words	TF IDF		Acuracy	Precision	Recall	Train Time
			Mean	0.8907	0.8977	0.8370	1.0673
0	0	0	Std	0.1607	0.1551	0.1912	0.1536
			Mean	0.8880	0.8819	0.8042	0.9616
0	0	1	Std	0.1511	0.1577	0.1978	0.1084
			Mean	0.8878	0.8463	0.8397	0.6467
0	1	0	Std	0.1691	0.2340	0.2039	0.0727
			Mean	0.9000	0.8994	0.8548	0.7094
0	1	1	Std	0.1510	0.1506	0.1678	0.0914
		0.0.0.0	Mean	0.8874	0.8487	0.8456	2.8228
1	0	0	Std	0.1659	0.2296	0.2086	0.3105
			Mean	0.8910	0.9007	0.8259	0.8009
1	0	1	Std	0.1497	0.1500	0.1860	0.2264
			Mean	0.8918	0.8492	0.8551	0.6037
1	1	0	Std	0.1695	0.2337	0.2066	0.0791
			Mean	0.8863	0.8438	0.8318	0.6363
1	1	1	Std	0.1652	0.2287	0.2049	0.0864

Melhor Modelo

					MI	LP	
Lower		TF IDF		Accuracy	Precision	Recall	Train Time
			Mean	0.9028	0.8746	0.8876	5.1970
1	1	0	Std	0.1513	0.1615	0.1569	0.8987

					Logistic R	egression	
Lower	Stop Words	TF IDF		Accuracy	Precision	Recall	Train Time
			Mean	0.8988	0.8949	0.8654	0.1373
1	1	0	Std	0.1564	0.1542	0.1719	0.0129

Tunning

- Penalty
- (
- Solver

GridSearchCV Acuracy	GridSearchCV Precision	GridSearchCV Recall	GridSearchCV Train Time
0.532608695652174	0.6022104108664473	0.6840092235891913	16.709161520004272
0.9962264150943396	0.98	0.9979253112033195	14.215339183807373
0.9076923076923077	0.9152661064425771	0.8504728132387707	15.733324766159058
0.7183098591549296	0.6123188405797102	0.5151960784313725	11.940999984741211
1.0	1.0	1.0	14.29494333267212
0.989100817438692	0.969005956813105	0.9850789372352715	11.966851234436035
0.994444444444445	0.9946808510638299	0.9942528735632183	14.028168439865112
0.9843260188087775	0.9514541715628673	0.9341101694915255	12.386742353439331
0.9653465346534653	0.9686238902340598	0.9618673560703987	8.241345405578613
1.0	1.0	1.0	14.570685148239136

	GridSearchCV Acuracy	GridSearchCV Precision	GridSearchCV Recall	GridSearchCV Train Time
mean	0.9088055092939131	0.8993560227562597	0.8922912762823068	13.408756136894226
std	0.15803331512515031	0.15604523971403092	0.16575994734160307	2.3908620783826193

Wrapper

Exemplo de informações relevantes

Smartphone Xiaomi Mi 8 Lite 64GB 4GB RAM Preto

por Xiaomi

★★★★ ✓ 994 avaliações de clientes

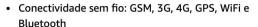
1000+perguntas respondidas

Preço: R\$1.019,00

Em até 10x R\$ 101,90 sem juros Calculadora de

prestações Y Cor: Preto





- Armazenamento externo até 256 GB
- Memória Interna: 64 GB
- Câmera Frontal: 24.0 MP
- Tela 6.26"

Nome do produto	Celular Smartphone Galaxy Notel0+ 6,8" 256GB Samsung - Preto
SKU	309904-2
Marca	Samsung
Código de barras	7892509109901
Garantia de fabrica	12 meses

Informações do produto

Smartphone Samsung Galaxy A10 32GB Preto 4G - 2GB RAM 6.2" Câm, 13MP + Câm, Selfie 5MP

Tela 6.2" Polegadas Câmera frontal de 5 MP Câmera traseira 13 MP Processador Octa-Core 1.6GHz Memória Ram de 2 GB Memória 32 GB, expansível até 512 GB

Itens Inclusos: Aparelho celular carregador cabo USB fone de ouvido

Extrator de Chip Manual do usuário

Campos buscados

- 1. Preço
- 2. Sistema operacional
- 3. RAM
- 4. Capacidade de armazenamento digital
- 5. Modelo
- 6. Cor
- 7. Tamanho da tela
- 8. Avaliações de clientes

Informações sobre o produto

Cor: Preto

Detalhes técnicos

Sistema operacional	android
RAM	6
Baterias ou pilhas	1 Polímero de litio baterias ou pilhas necessárias (inclusas).
Modelo	MZB7606EU
Tecnologia sem fio	Bluetooth, 4G, NFC, GPS
Tecnologia de conexão	A-GPS, USB-C, 4G, NFC, Bluetooth Wireless, GPS
Cor	Preto
Classificação de potência da bateria ou pilha	3070 milliampere_hour
Tamanho da tela	5.97 polegadas
Tamanho da memória RAM instalada	6 GB
Capacidade de armazenamento digital	6 GB

Informações adicionais

Dimensões do pacote	18,5 x 9,4 x 5,8 cm
Peso do produto	154 g
Dimensões do produto	14,8 x 7,1 x 0,7 cm
Peso do envio	481 g
Baterias ou pilhas	1 Polímero de lítio baterias ou pilhas necessárias (inclusas).
Modelo	MZB7606EU
ASIN	B07QH823FV
Código de barras:	6941059622345
Primeira data disponível	10 de abril de 2019
Avaliações de clientes	★★★★ 109 avaliações de clientes
Lista de mais vendidos da Amazon	Nº 853 em Eletrônicos (Conheça o Top 100 na categoria Eletrônicos) Nº292 em Celulares e Smartphones Desbloqueados

Extratores Individuais

- Biblioteca BeautifulSoup em conjunto com regex
- XPath

'Preco': 'R\$1.998,00',

- Distância de Levenshtein
- Dificuldades:
 - Nomenclatura varia de fabricante
 - Poucas informações
 - Encontrar o valor de venda correto.
 - Informações importantes presente em imagens

Preço sugerido: R\$8.999,90

Preço: R\$6.799,99

Você economiza: R\$2.199,91 (24%)

R\$ 464,10 10x de R\$ 46,41 sem juros

ou 12x de R\$ 42,52 com juros * total a prazo R\$ 510,27

```
XPATH_MODEL = r"""//*[@id="pag-detalhes"]/div/div[6]/div[2]/p/text()"""
```

```
'Sistema operacional': 'android',
'RAM' : '6',
'Capacidade de armazenamento digital': '6 GB',
'Modelo': 'MZB7606EU',
'Cor' : 'Preto',
'Tamanho da tela': '5.97 polegadas',
'Avaliações de clientes': '4.7 de 5 estrelas 109
avaliações de clientes '}
```

```
price_roi = s.find_all("div", attrs={"class":"preco_normal"},text=True)
if len(price_roi):
    price = re.findall("R\$ \d{1,5}\,\d{1,3}", str(price_roi[0]))
    if len(price):
        fields_kabum["Preço"] = price[0]
```